BIT BUILD INNOVATE TRANSFORM

BIT BUILD INNOVATE TRANSFORM

MÓDULO 2 · PYTHON PARA ANÁLISIS DE DATOS — CLASE 7

Limpieza y transformación

Del dato sucio al dato confiable

Bootcamp de Ciencia de Datos · 2 horas · Funciones de limpieza y transformación con Pandas, aplicadas

BIENVENIDA

El mapa del bootcamp: 6 módulos, 32 clases

MÓDULO 1

Fundamentos y Mentalidad de Datos

Completado

MÓDULO 2

Python para Análisis de Datos

Estamos aquí

MÓDULO 3

Visualización y Business Intelligence

Gráficas, EDA, Power BI

MÓDULO 4

Extracción de Datos

Bases de datos, SQL, APIs

MÓDULO 5

Machine Learning Básico y Aplicado

Clasificación, regresión, clustering

MÓDULO 6

Proyecto Final y Cierre

Deep Learning, NLP, tu proyecto

32 CLASES

Tu recorrido completo

Mayo a septiembre, 2 clases por semana

CÓMO TRABAJAMOS

Teoría + práctica en cada módulo · talleres integradores · proyecto final

Hoy aprendes a preparar los datos: sin esta etapa, ningún análisis posterior es confiable.

POR QUÉ HOY IMPORTA

Los datos nunca llegan perfectos

Datos sucios, resultados falsos

Lo que haces antes de analizar

- En el mundo real, los datos traen duplicados, errores de digitación y formatos mezclados.
- Un duplicado infla una venta; un salario guardado como texto no se puede promediar.
- Pandas permite detectar y corregir estos problemas de forma rápida y repetible.
- Suele ser el paso que más tiempo toma en un proyecto de datos.

¿Por qué justo ahora?



Ya sabes explorar una tabla

En la clase anterior cargaste, filtraste y resumiste datos. Hoy los preparas antes de hacerlo.



Cada error cambia el resultado

Un departamento mal escrito divide un grupo en dos; un valor atípico distorsiona un promedio.



Prepara el terreno para el EDA

El archivo limpio que exportes hoy es la entrada del análisis exploratorio.

Hoy conviertes un archivo lleno de errores en uno limpio.

CLASE 7

Lo que vamos a lograr hoy

01

Diagnosticar un dataset sucio

Detectar duplicados, texto inconsistente, tipos incorrectos y valores faltantes.

02

Limpiar y convertir

Usar drop_duplicates, .str, to_numeric, fillna y to_datetime para corregir cada problema.

03

Dejar el dato listo

Exportar un CSV limpio, listo para el análisis exploratorio o para Power BI.

Al final de la clase: el archivo de empleados limpio, con tipos correctos y sin duplicados.

MÓDULO 2 · LIMPIEZA

Entonces, ¿qué es limpiar datos?

Detectar y corregir los problemas de un dataset para que sea confiable antes de analizarlo: sin cambiar lo que los datos significan, solo cómo están escritos.



Duplicados

Filas repetidas que inflan los resultados.



Texto inconsistente

Espacios sobrantes y errores como Vntas en vez de Ventas.



Tipos incorrectos

Números y fechas guardados como texto, imposibles de calcular.



Nulos y atípicos

Valores faltantes y datos imposibles, como una edad de 999.

Chequeo rápido: en el archivo de empleados, ¿qué problema crees que más daño haría a un promedio de salarios?

MÓDULO 2 · LIMPIEZA

Tres herramientas, tres problemas

Texto

Para limpiar cadenas.

- .str.strip() quita espacios
- replace() corrige con un diccionario
- unique() verifica el resultado

Vntas pasa a Ventas

Tipos

Para convertir datos.

- str.replace() quita símbolos
- to_numeric(errors='coerce')
- to_datetime() para fechas

Texto pasa a número

Vacíos

Para completar o corregir.

- fillna() rellena los nulos
- loc marca los atípicos como NaN
- La mediana resiste los extremos

999 años pasa a NaN

La regla de oro: diagnostica primero, corrige después y verifica siempre el resultado.

MÓDULO 2 · LIMPIEZA

El flujo de limpieza, paso a paso

Duplicados

Cuentas y eliminas las filas repetidas

drop_duplicates()

→

Texto

Quitas espacios y corriges los departamentos

strip() y replace()

→

Números

Limpias símbolos y conviertes el salario

to_numeric()

→

Nulos

Corriges atípicos y rellenas con la mediana

fillna() y loc

→

Fechas

Unificas los formatos bajo un mismo estándar

to_datetime()

La idea clave: cada paso resuelve un solo problema, y al final exportas con to_csv() un archivo limpio, listo para el análisis exploratorio.

RECAPITULEMOS

Las 4 ideas que se llevan hoy

01 **Los datos reales nunca llegan limpios**

Duplicados, texto, tipos y nulos: cada uno cambia el resultado si no se corrige.

02 **Cada problema tiene su herramienta**

drop_duplicates, .str, to_numeric, fillna y to_datetime resuelven uno cada uno.

03 **coerce convierte en nulo lo imposible**

Es útil, pero silencioso: verifica cuántos valores se convirtieron.

04 **Limpiar es tomar decisiones**

Imputar con la mediana o dejar un nulo son elecciones que debes poder justificar.

Mini-reto de salida (1 frase): explícale a alguien por qué la mediana es más segura que la media para rellenar la edad.